

Instituto Politécnico Nacional



Unidad Profesional Interdisciplinaria en Ingeniería y
Tecnologías Avanzadas

Proyecto Terminal 1

Sistema de reconocimiento de señas de detección de palabras para el
lenguaje de señas LSM

Que para obtener el título de

“Ingeniero en Telemática”

Presenta(n):

Jose Daniel Alvarez Ramos

Asesor(es):

M. en C. Bella C. Martínez Seis



Barrio la Laguna Ticomán, D.F., a 10 de octubre de 2024.

Índice general

Índice de figuras	4
Índice de tablas	5
Índice de ecuaciones	6
Resumen	7
Abstract	8
1 Introducción	9
1.1 Planteamiento del problema	10
1.2 Propuesta de solución	11
1.2.1 Descripción del sistema	11
1.3 Alcances y limitaciones	13
1.4 Justificación	13
1.5 Metodología	14
1.6 Objetivos	15
1.6.1 Objetivo general	15
1.6.2 Objetivos específicos	15
2 Marco Teórico	16
2.1 MediaPipe Holistic	16
2.1.1 Componentes del Modelo Holistic	16
2.1.2 Ventajas de MediaPipe Holistic	17
2.2 TensorFlow/Keras	18
2.3 Procesamiento Híbrido (Local y en la Nube)	18
2.4 Amazon Web Services (AWS)	18
2.5 Lingüística de la Lengua de Señas Mexicana (LSM)	18
2.6 Diccionarios y Bases de Datos de LSM	18
2.7 Arquitectura de Microservicios	19
2.8 Redes Neuronales	19
2.8.1 Redes Neuronales Convolucionales (CNN)	19
2.9 Redes Neuronales Recurrentes (RNN) para Señas Dinámicas	20
2.9.1 LSTM (Long Short-Term Memory)	20
2.10 Funciones de Activación	20
2.10.1 Función Sigmoide	20
2.10.2 Función Tangencial Hiperbólica (tanh)	22
2.10.3 Función ReLU (Rectified Linear Unit)	23
2.10.4 Función Softmax	24
2.11 Entrada de Arreglos Fila (Vectores)	25
2.12 Datasets para el Reconocimiento de LSM	25
2.12.1 Características de los Datasets	25
2.12.2 Entrada de Datos al Modelo	26

3	Estado del arte	27
3.1	Dispositivo traductor de LSM a español escrito para la extremidad superior derecha [29]	27
3.2	Reconocimiento de las señas estáticas del LSM con características basadas en aprendizaje profundo [30]	27
3.3	Sistema de interpretación de imágenes para el reconocimiento y traducción del lenguaje de señas [31]	28
3.4	Desarrollo de un intérprete de 20 frases en lengua de señas ecuatoriana a voz en tiempo real usando redes neuronales recurrentes [32]	28
3.5	Las redes neuronales convolucionales en el uso de lenguaje de señas en la gestión académica de los estudiantes para SENATI [33]	28
3.6	Diseño e implementación de un sistema de traducción de lenguaje de señas dactilológico a lenguaje natural escrito para personas no hablantes mediante visión artificial [34]	28
3.7	Reconocimiento de señas de la Lengua de Señas Mexicana mediante técnicas de Machine Learning [35]	29
3.8	Desarrollo de un Sistema Web intérprete de la Lengua de Señas Argentina [29]	29
3.9	Desarrollo de algoritmos para Traductor automático de lenguaje de señas Mexicanas (LSM) [36]	29
3.10	Sistema multi-agente de reconocimiento de frases en LSM utilizando CBR [37]	30
3.11	Modelos Computacionales Aplicados a la Lengua de Señas Mexicana [38]	30
3.12	Modelo para la creación y uso de un repositorio digital de segmentos visuales en lengua de señas mexicanas utilizando Inteligencias Artificial [39]	30
4	Análisis	31
4.1	Análisis de Requerimientos del Sistema	31
4.1.1	Funcionalidad del sistema	31
4.2	Requerimientos Funcionales (RF)	33

Índice de figuras

1.1	Diagrama del funcionamiento del sistema	12
1.2	Metodología Scrum	14
2.1	Puntos de medipipe	17
2.2	Acción de Convolución	20
2.3	Gráfica de la función sigmoide.	21
2.4	Gráfica de la función tangencial hiperbólica ($\tanh$).	22
2.5	Gráfica de la función ReLU.	23
2.6	Gráfica de la función de activación Softmax considerando tres valores fijos $z = -1, 0, 1$	24
4.1	Diagrama de casos de uso del Sistema Principal	32

Índice de tablas

4.1	Requerimiento: Registro de Usuario	33
4.2	Requerimiento: Inicio de la App	33
4.3	Requerimiento: Login	33
4.4	Requerimiento: Autenticación de Credenciales	34
4.5	Requerimiento: Perfil	34
4.6	Requerimiento: Destacados	34
4.7	Requerimiento: DLM (Ver Información de la Señal)	34
4.8	Requerimiento: Inicio del Sistema	35
4.9	Requerimiento: Captura de Señal a Identificar	35
4.10	Requerimiento: Reconocer	35
4.11	Requerimiento: Registra Información de Señal DLM	36
4.12	Requerimiento: Captura de Señal en Bucket	36

Índice de ecuaciones

2.3 Función de activacion Sigmoide	20
2.4 Función de activacion (tanh)	22
2.5 Función tanh	22
2.6 Función de activacion Relu	23
2.7 Función de activación Softmax	24
2.8 Matriz A	26

Resumen

Este proyecto busca desarrollar un sistema que reconozca señas estáticas de la Lengua de Señas Mexicana (LSM) para facilitar la comunicación entre personas con discapacidad auditiva y la comunidad oyente en México. El sistema se basa en la captura de la configuración manual de las señas mediante webcams y utiliza MediaPipe para el seguimiento de las manos. Se enfoca principalmente en el reconocimiento de posturas fijas, con la posibilidad de incluir señas con movimiento si el tiempo lo permite. La traducción precisa de un conjunto predefinido de señas estáticas al español se logrará mediante modelos de aprendizaje profundo, utilizando TensorFlow/Keras. La integración de tecnología en la nube permitirá un procesamiento de datos escalable y una posible traducción en tiempo real. El objetivo final es cerrar la brecha de comunicación entre personas con discapacidad auditiva y oyentes, promoviendo una mayor inclusión y accesibilidad en México.

keywords: Lengua de Señas Mexicana (LSM), Reconocimiento de Señas, Seguimiento de Manos (Hand Tracking), Algoritmos de Aprendizaje Automático, Redes Neuronales Convolucionales (CNN), Redes Neuronales LSTM, Automatización de Procesos, AWS (Amazon Web Services), Sistemas de Mensajería (SQS), Interfaz de Usuario, Análisis de Datos.

Abstract

This project proposes a system for recognizing static signs in Mexican Sign Language (LSM) to facilitate communication between people with hearing disabilities and the hearing community in Mexico. Using webcams for hand tracking and focusing on the manual configuration of signs, the system captures and processes sign language through MediaPipe. The goal is to accurately translate a predefined set of static signs into Spanish, employing deep learning models trained with TensorFlow/Keras. By incorporating cloud technology for scalable data processing and potential real-time translation, this project aims to bridge the communication gap, promoting greater inclusion and accessibility for people with hearing disabilities in Mexico.

Keywords: Accessibility, Computer Vision, Deep Learning, Hand Tracking, Human-Computer Interaction, Mexican Sign Language (LSM), Sign Language Recognition.

Capítulo 1

Introducción

En la actualidad, en México, existen alrededor de 7.1 millones de personas que presentan algún tipo de discapacidad, lo que representa aproximadamente el 6 % de la población total. Estas personas enfrentan desafíos constantes de discriminación en diversas actividades, ya sean laborales, académicas o sociales [1].

Entre este grupo se encuentran personas con hipoacusia, una disminución significativa de la capacidad auditiva, quienes han utilizado históricamente la lengua de señas como su principal medio de comunicación. En México, la Lengua de Señas Mexicana (LSM) y la Lengua de Señas Maya Yucateca (LSMY) son las dos lenguas más reconocidas para este propósito, con la LSM siendo la más utilizada por aproximadamente 87,000 a 100,000 señantes y declarada como lengua nacional desde 2003 [2].

El presente sistema se propone como una herramienta de apoyo a personas con hipoacusia, facilitando la traducción de señas de la LSM a palabras en español mexicano, bajo el código ISO 639-2 sgn-MX. En esta solución se incorporan tecnologías más avanzadas y escalables como MediaPipe para el seguimiento y procesamiento de los movimientos de las manos [3], junto con TensorFlow/Keras para la creación de modelos de aprendizaje profundo que permiten una mayor precisión en la interpretación de las señas [4]. La integración de servicios en la nube, como AWS S3 y SQS, también garantiza la escalabilidad y el procesamiento de los datos [5].

Al integrar una API de Text-To-Speech u otras alternativas similares, genera un sistema versátil que convierte las señas en palabras tanto visuales como auditivas, ofreciendo una interacción más inclusiva.

1.1. Planteamiento del problema

Las personas que cuentan con la condición de hipoacusia tienen la perentoriedad de recurrir a herramientas, en su mayoría tecnológicas, que les ayuden o permitan entablar contacto con una inmensa mayoría que desconoce su modo de comunicación [6]. Estas personas enfrentan desafíos significativos al comunicarse con quienes no conocen la lengua de señas, lo que limita sus interacciones sociales, laborales y educativas, creando barreras que dificultan su inclusión en la sociedad [7]. Aunque existen herramientas que facilitan la traducción de español a Lengua de Señas Mexicana (LSM), la traducción inversa de LSM a español sigue siendo un área poco explorada, con un gran potencial de mejora [8].

Una forma de cerrar esta brecha de comunicación es identificar la palabra que corresponde a la seña interpretada. Para ello, se han creado diversas herramientas lingüísticas, siendo el diccionario una de las principales, donde cada palabra es representada por una o varias imágenes y una descripción escrita que presenta el paso a paso para realizar la seña [9].

En el marco tecnológico, uno de los principales retos es la correcta interpretación de las señas. El uso de sensores presenta oportunidades; sin embargo, herramientas como Kinect no son suficientes debido a sus limitaciones en la detección precisa de las posiciones de las manos [10]. Dispositivos como Leap Motion ofrecen una mejor captura de los movimientos, pero aún se necesita desarrollar un sistema que interprete las señas de manera efectiva [11].

Para abordar esta problemática, proponemos un sistema innovador que utiliza tecnologías avanzadas como MediaPipe y TensorFlow/Keras. El objetivo primordial de este sistema es enfocarse en las señas de detención estática. Sin embargo, este es solo el primer paso; se prevé que en caso de contar con tiempo, se podrían incluir otros tipos de señas a través de video (secuencia de fotogramas). Ejemplos de estas otras señas podrían incluir saludos, preguntas básicas o expresiones emocionales. El proceso inicia con el usuario grabando su comunicación en LSM mediante un programa que captura video o imágenes. Estos archivos de fotogramas son enviados a un almacenamiento en la nube para su procesamiento.

A través de un microservicio, los fotogramas se procesan para extraer puntos clave que representan las señas, utilizando principalmente la captura de las manos mediante MediaPipe. Estos puntos clave se visualizan en la secuencia de fotogramas representativa de la seña o en la imagen, facilitando la identificación de las posiciones y movimientos correspondientes. Estos datos son empleados para entrenar un modelo de aprendizaje profundo que mejora la precisión de la traducción de LSM a español [12]. Una vez entrenado, el modelo permite al usuario traducir las señas que se capturan a través de una cámara.

El sistema no solo genera una representación visual de la palabra traducida en pantalla, sino que también utiliza una API (de Text-To-Speech o similar) para reproducir el audio correspondiente, facilitando así una comunicación inclusiva y efectiva [13]. Este enfoque integral no solo cierra la brecha comunicativa, sino que también empodera a las personas con hipoacusia, brindándoles herramientas que fomentan su participación en la sociedad.

1.2. Propuesta de solución

1.2.1. Descripción del sistema

En la Figura 1.1, se observa el principio básico del funcionamiento del sistema:

1. Iniciar Grabación o toma de la muestra: El usuario inicia el programa de grabación o toma de fotos.
2. Captura de Video (secuencia de fotos representativa de la seña) o Fotos: El programa de grabación utiliza la cámara para capturar video o fotos.
3. Dividir en Fotogramas: El video capturado se divide en fotogramas para un análisis más fácil.
4. Almacenamiento Local: Los fotogramas se almacenan temporalmente en el almacenamiento local.
5. Subir Fotogramas a S3: Los fotogramas se suben al servicio de almacenamiento en la nube (AWS S3).
6. Notificación de Nuevo Archivo: EventBridge notifica que se ha subido un nuevo archivo a S3.
7. Invocar Función Lambda: EventBridge invoca una función en AWS Lambda para procesar los fotogramas.
8. Obtener Fotogramas: La función Lambda obtiene los fotogramas desde S3.
9. Enviar Paquete de Fotogramas a SQS: Lambda envía un paquete de 30 fotogramas (URLs de los archivos en S3) a una cola de mensajes (SQS).
10. Recibir Datos en Microservicio: El microservicio recibe los datos desde SQS (Comienza con la descarga de los mismos desde S3).
11. Procesar Frames con MediaPipe: MediaPipe procesa los fotogramas para detectar puntos clave (señas).
12. Enviar DataFrame: El microservicio envía el DataFrame resultante.
13. Entrenar Modelo: Un entrenador recibe el DataFrame y utiliza TensorFlow/Keras para entrenar el modelo de traducción.
14. Guardar Pesos del Modelo: Los pesos entrenados se guardan en el almacenamiento.
15. Iniciar Traducción por el Usuario: El usuario inicia el programa de traducción.
16. Capturar Frames en Tiempo Real o Foto: Se captura frames en foto o tiempo real mediante una cámara local o WebSocket.
17. Predecir Palabra: El modelo predice la palabra correspondiente a las señas capturadas.
18. Mostrar Palabra en Pantalla: La palabra traducida se muestra en la pantalla.
19. Genera Audio con Text-To-Speech: Se envía la palabra a una API de Text-To-Speech para generar audio.
20. Reproducir Audio en Altavoz: El audio generado se reproduce a través de un altavoz.



Figura 1.1: Diagrama del funcionamiento del sistema

1.3. Alcances y limitaciones

En resumen, los resultados que se esperan ser obtenidos son los siguientes:

- **Reconocimiento de Señas Estáticas:** El sistema se enfocará en el reconocimiento preciso de un conjunto predefinido de señas estáticas de detención dentro de la Lengua de Señas Mexicana (LSM).
- **Ambiente Controlado:** El sistema funcionará de manera óptima en un ambiente interior sin incidencia directa de luz solar, para garantizar la calidad de la captura de imágenes por la cámara y la API de hand tracking.
- **Configuraciones Manuales:** Se deberá contar con configuraciones manuales otorgadas por la API de hand tracking, las cuales constituyen una característica importante, como la posición de manos y los dedos.
- **Señas de Convención:** Existe una similitud léxica alrededor del país de 80 % a 90 %, esto quiere decir que existe una variación dialectal, de acuerdo con la región del país, lo que se buscará es solo utilizar señas como convención por la mayoría de sordos [14].
- **Reconocimiento de Manos y Muñeca:** El sistema se limitará al reconocimiento de manos y muñeca, dentro del espectro permisible para la cámara y la API de hand tracking.

Limitaciones del Sistema

Por el contrario, es pertinente mencionar lo que no se pretende con este sistema:

- **No Reconocimiento de Frases o Textos:** El sistema no busca hacer reconocimiento de frases, o textos de mayor envergadura únicamente de palabras, dado a que la estructura gramatical de la LSM es muy diferente al español, cabe hacer mención que existe el español signado, pero no este no está dentro del enfoque en la problemática a solucionar [15].
- **No Deletreo:** Tampoco se busca hacer el reconocimiento de palabras por medio de deletreo, dado que ya existen sistemas que realizan esta tarea, de igual manera no representa una manera eficiente de expresarse.

1.4. Justificación

En México, el 33.5 % de las personas con discapacidad tiene una discapacidad auditiva y un 18 % presenta dificultades del habla, lo que significa que más del 51 % de este grupo se beneficiaría directamente de herramientas que faciliten la comunicación (Instituto Nacional de Estadística y Geografía [1]. Para los miles de personas que dominan la Lengua de Señas Mexicana (LSM), este proyecto proporciona una plataforma que les permite transmitir mensajes a quienes no están familiarizados con esta lengua, enfatizando su importancia para la inclusión social [16]. Los estudios muestran que las personas con hipoacusia que tienen un nivel educativo más alto suelen tener un mayor dominio del español, debido a su acceso a recursos como libros e internet. Sin embargo, la falta de señas para ciertos conceptos limita su capacidad comunicativa, lo que a menudo lleva al uso del deletreo de señas en lugar del español signado. Este trabajo busca desarrollar un sistema de diccionario de palabras en LSM que permita la traducción de señas a palabras en español, apoyado por la tecnología actual [17]. Los diccionarios no solo proveen información lingüística, sino que también desempeñan funciones sociales significativas, como fomentar la identidad cultural y cohesionar a la comunidad [18]. La función primordial y más conocida de un diccionario es proveer información sobre una lengua, un diccionario además conlleva otras funciones sociales como dar identidad, función histórica y cohesión de la sociedad [19].

1.5. Metodología

Para el desarrollo de este sistema de reconocimiento de LSM, se adoptó una metodología ágil inspirada en Scrum, la cual se basa en ciclos iterativos de desarrollo conocidos como sprints. Este enfoque, que prioriza la flexibilidad y la colaboración, se adapta de manera ideal a la naturaleza dinámica del proyecto, permitiendo la incorporación de mejoras y ajustes a lo largo del proceso. La adaptación de Scrum a este proyecto implica un enfoque iterativo en el desarrollo del sistema de reconocimiento de LSM. Se priorizarán las funcionalidades esenciales en los primeros sprints, como la captura y el procesamiento de las señas, y se irán incorporando nuevas funcionalidades, como la integración con la nube y la generación de audio, en sprints posteriores.

Este enfoque se inspira en la práctica descrita por Kniberg (2007), quien destaca varios principios clave de Scrum que aplican directamente a este proyecto[20]:

- **Enfoque en la práctica:** Scrum se centra en la aplicación práctica, lo que permite que el equipo se adapte a las necesidades del proyecto de manera eficiente.
- **Adaptabilidad:** La metodología se ajusta al contexto específico del proyecto, permitiendo mayor flexibilidad en lugar de seguir un conjunto rígido de reglas.
- **Colaboración:** La comunicación y colaboración entre el equipo de desarrollo y el Dueño de Producto son esenciales, especialmente durante la planificación de cada sprint.
- **Entrega continua:** Al final de cada sprint, se promueve la entrega de software funcional, asegurando que el producto esté en constante evolución y mejora.
- **Mejora continua:** A través de retrospectivas, el equipo analiza y mejora su proceso en cada sprint.
- **Simplicidad:** El proyecto se gestiona de manera simple, utilizando herramientas como tarjetas físicas para la organización del backlog del producto y del sprint.
- **Transparencia:** La transparencia en el progreso es fundamental, y se asegura mediante un tablón de tareas visible para todo el equipo y una página de información del sprint para mantener informada a toda la organización.

En la 1.2 se presenta un esquema de las etapas que conforman la metodología SCRUM:




Figura 1.2: Metodología Scrum [21]

1.6. Objetivos

1.6.1. Objetivo general

Desarrollar un sistema de reconocimiento de señas estáticas de la LSM, con una arquitectura híbrida que combine componentes *on-premise* y en la nube. Se utilizará MediaPipe u otra API de *hand tracking* para la captura y procesamiento de datos, enfocándose en señas de configuración manual o de reposo y parametrizando las principales articulaciones manuales en un sistema de coordenadas rectangulares. A partir de estos datos, se entrenará un modelo de clasificación utilizando TensorFlow para reconocer y asociar las señas a su equivalente en español. La palabra reconocida será reproducida utilizando una API de voz (*speech-to-text*).

1.6.2. Objetivos específicos

1. Recopilación de Datos:

- Recopilar un conjunto de datos representativo de señas estáticas de detención en LSM, incluyendo variaciones dialectales comunes, y etiquetarlas con su significado en español.
- Utilizar una cámara web para capturar de las señas, asegurando una calidad adecuada en un ambiente controlado. Extraer una secuencia de fotogramas representativa de cada seña para su posterior procesamiento.
- Utilizar MediaPipe para extraer los puntos clave de las articulaciones de las manos en un sistema de coordenadas rectangulares.

2. Modelado y Entrenamiento:

- Seleccionar y adaptar un modelo de reconocimiento existente, como una red neuronal convolucional (CNN), para el reconocimiento de señas estáticas [22].
- Entrenar un modelo de reconocimiento de señas utilizando técnicas de aprendizaje automático (TensorFlow/Keras) con los datos recopilados y etiquetados.

3. Diseño del Almacenamiento de Datos:

- Diseñar e implementar una estructura de almacenamiento eficiente que combine una base de datos y un *bucket* (como S3) para gestionar la información recopilada. La base de datos almacenará metadatos de las señas (traducciones, parámetros de articulaciones, configuraciones manuales), mientras que el *bucket* almacenará las imágenes de las señas. Se asegurará la integridad de los datos y se facilitará el acceso a ambos tipos de información para el entrenamiento, la ejecución y el mantenimiento del sistema.

4. Desarrollo de la Salida y Configuración:

- Implementar un mecanismo de salida claro y accesible para presentar la traducción de la seña reconocida, ya sea en texto, audio (utilizando una API de *Text-To-Speech*) o ambos, según los requisitos del usuario final.
- Considerar la posibilidad de desarrollar una interfaz web intuitiva para interactuar con el sistema, si los recursos y el alcance del proyecto lo permiten.

Capítulo 2

Marco Teórico

2.1. MediaPipe Holistic

MediaPipe Holistic es una solución integral de Google para el seguimiento del cuerpo humano en tiempo real. El modelo de Holistic combina modelos de aprendizaje profundo para detectar y rastrear puntos (posiciones flotantes en un plano x, y) clave en el rostro, las manos y el cuerpo completo. Esta capacidad de análisis detallado de los movimientos corporales es esencial para la captura expresiva de la Lengua de Señas Mexicana (LSM), donde la posición del cuerpo y los movimientos de las manos son fundamentales para recibir y generar la comunicación.

2.1.1. Componentes del Modelo Holistic

MediaPipe Holistic se compone de tres modelos principales:

1. Pose Landmarker:

- **Descripción:** Este modelo detecta 33 puntos de referencia del cuerpo humano en una imagen o video, incluyendo la nariz, los ojos, las orejas, los hombros, los codos, las muñecas, las caderas, las rodillas y los tobillos.
- **Aplicaciones en LSM:** Estos puntos son cruciales para interpretar las señas, ya que permiten analizar la postura general del cuerpo y la posición de los brazos y las manos en relación al torso. Por ejemplo, la posición de los codos y las muñecas es fundamental para distinguir señas como “CASA”u “HOLA”.
- **Imágenes de referencia:** [Imagen de los 33 puntos de referencia de Pose Landmarker superpuestos en una persona signando]
- **Funcionamiento:** El modelo utiliza una red neuronal convolucional similar a MobileNetV2 y está optimizado para aplicaciones de entrenamiento en tiempo real y en el dispositivo. Primero, detecta la presencia de cuerpos humanos en la imagen, y luego localiza los 33 puntos de referencia en el cuerpo detectado.
- **Opciones de configuración:**
 - **running_mode:** Establece el modo de ejecución (IMAGE, VIDEO, LIVE_STREAM).
 - **num_poses:** La cantidad máxima de poses a detectar.
 - **min_pose_detection_confidence:** Puntuación mínima para la detección de poses.
 - **min_pose_presence_confidence:** Puntuación mínima de presencia de poses.
 - **min_tracking_confidence:** Puntuación mínima para el seguimiento de poses.
 - **output_segmentation_masks:** Si se generan máscaras de segmentación.

2. Face Landmarks:

- **Cantidad:** 468 puntos.
- **Descripción:** Detecta puntos clave en el rostro, como los ojos, las cejas, la nariz, la boca y el contorno de la cara.
- **Aplicaciones en LSM:** Se utilizan para analizar las expresiones faciales, que son un componente gramatical crucial en la LSM. Por ejemplo, las expresiones faciales pueden indicar preguntas, negación, o emociones.

3. Hand Landmarks:

- **Cantidad:** 21 puntos por cada mano [23].
- **Descripción:** Detecta puntos clave en las manos, como las puntas de los dedos, los nudillos y la palma.
- **Aplicaciones en LSM:** Permite analizar la forma, orientación y movimiento de las manos, lo cual es fundamental para identificar los diferentes queremas (formas de la mano) en la LSM.




Figura 2.1: Puntos de medipipe [23]

2.1.2. Ventajas de MediaPipe Holistic

- **Integración completa:** Combina el seguimiento de rostro, manos y cuerpo en un solo framework, lo que facilita el desarrollo de aplicaciones de LSM.
- **Rendimiento en tiempo real:** Permite procesar imágenes en tiempo real, lo que es crucial para la fluidez en la traducción de LSM.
- **Eficiencia computacional:** Está optimizado para ejecutarse en dispositivos móviles y de escritorio, con bajo consumo de recursos.
- **Robustez:** Funciona en diferentes condiciones de iluminación y con diferentes tipos de cámaras.
- **Facilidad de uso:** MediaPipe ofrece APIs fáciles de usar para integrar Holistic en aplicaciones de Python, Android y web.

2.2. TensorFlow/Keras

TensorFlow, una plataforma de aprendizaje automático de código abierto, y Keras, una interfaz de alto nivel para construir y entrenar modelos de redes neuronales, son herramientas esenciales en el desarrollo de modelos de aprendizaje profundo. Estos modelos, entrenados con datos de LSM, son capaces de reconocer y clasificar señas, formando la base del sistema de traducción [24].

2.3. Procesamiento Híbrido (Local y en la Nube)

El enfoque híbrido combina el procesamiento local en el dispositivo del usuario con el procesamiento en la nube a través de Amazon Web Services (AWS). Esta estrategia aprovecha las ventajas de ambos entornos: el procesamiento local reduce la latencia y protege la privacidad, aspectos cruciales al tratar con datos sensibles como la comunicación en LSM, mientras que la nube ofrece potencia de cómputo escalable para tareas intensivas, como el entrenamiento de modelos y el almacenamiento de datos [25].

2.4. Amazon Web Services (AWS)

AWS proporciona una amplia gama de servicios en la nube que son fundamentales para el proyecto:

- **Buckets S3:** Almacenamiento escalable y seguro para grandes volúmenes de datos de LSM, como videos y modelos de aprendizaje profundo.
- **Colas SQS:** Facilitan la comunicación asincrónica entre los diferentes microservicios del sistema, permitiendo el procesamiento eficiente y desacoplado de solicitudes de traducción.
- **Funciones Lambda:** Ejecutan código sin necesidad de aprovisionar o administrar servidores, lo que permite escalar automáticamente el procesamiento de solicitudes de traducción según la demanda [5].

2.5. Lingüística de la Lengua de Señas Mexicana (LSM)

La LSM, como cualquier lengua natural, posee una gramática compleja que incluye aspectos como la configuración manual, la ubicación, la orientación y el movimiento de las manos, así como las expresiones faciales. El proyecto incorpora conocimientos lingüísticos de la LSM para asegurar una traducción precisa y culturalmente apropiada. La Matriz Segmental, que describe la estructura de las señas en términos de segmentos secuenciales, es una herramienta clave para el análisis y la representación de las señas en el sistema [26].

2.6. Diccionarios y Bases de Datos de LSM

Aunque existen diccionarios de LSM como "Manos con Voz", la falta de bases de datos estructuradas que contengan la gramática y el léxico de la LSM representa un desafío. El proyecto busca contribuir a la creación de tales recursos, beneficiando no solo a la traducción automática, sino también a la investigación y la enseñanza de la LSM.

2.7. Arquitectura de Microservicios

El proyecto adopta una arquitectura de microservicios en la parte del entrenamiento del modelo, donde cada componente del sistema se implementa como un servicio independiente y autónomo. Esta modularidad facilita el desarrollo, la implementación y el mantenimiento del sistema, permitiendo escalar y actualizar componentes individuales sin afectar el funcionamiento global [27].

2.8. Redes Neuronales

2.8.1. Redes Neuronales Convolucionales (CNN)

Las Redes Neuronales Convolucionales (CNN) son una red neuronal profunda con gran eficacia en el procesamiento de imágenes y videos. Esta capacidad se debe a su estructura, enfoca analizar datos organizados en forma de grilla, como es el caso de las imágenes. En el contexto de la traducción de la Lengua de Señas Mexicana (LSM), las CNN tienen un rol fundamental, ya que facilitan el análisis de las imágenes que capturan las señas realizadas por el usuario.

Las CNN se caracterizan por la inclusión de capas convolucionales. Estas capas emplean filtros (kernels), que se deslizan sobre la imagen de entrada para identificar y extraer características relevantes.

Convolución: Definición General

La convolución se puede definir como la integral del producto de dos funciones después de desplazar una de ellas una distancia t , como se observa en la ecuación 2.1:

$$S(t) = \int_{-\infty}^{\infty} x(a)w(t-a)da \quad (2.1)$$

donde:

- $x(a)$ Es la señal de entrada (entrada de la red).
- $w(t-a)$ Es la segunda función (kernel) desplazada una distancia t .
- $S(t)$ Es la función resultante de operar la convolución.

La salida (S) se conoce como mapa de características.

Convolución Discreta

Al tener que procesar datos en una computadora, el tiempo y la señal de entrada se discretizan. En consecuencia, la operación de convolución se adapta al dominio discreto, como se expresa en la ecuación 2.2:

$$S(t) = (x * w)(t) = \sum_{a=-\infty}^{\infty} x(a)w(t-a) \quad (2.2)$$

Convolución en Dos Dimensiones

Las imágenes son datos bidimensionales, por lo que la convolución se extiende a dos dimensiones. Si I representa la imagen de entrada y K representa el kernel, la convolución 2D se define como:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(m, n) K(i - m, j - n) \quad (2.3)$$

donde:

- $S(i, j)$ representa el valor del píxel en la posición (i, j) del mapa de características de salida.
- $I(m, n)$ representa el valor del píxel en la posición (m, n) de la imagen de entrada.
- $K(i - m, j - n)$ representa el valor del elemento en la posición $(i - m, j - n)$ del kernel.

Figura 2.2: *Acción de Convolución*

De esta manera, se ilustra la transición de la convolución en su forma general a la convolución discreta y, finalmente, a la convolución 2D empleada en las CNN para el procesamiento de imágenes.

2.8.2. Redes Neuronales Recurrentes (RNN) para el Análisis de Señas Dinámicas

Las Redes Neuronales Recurrentes (RNN) constituyen una clase de red neuronal artificial que se caracteriza por sus conexiones recurrentes, lo que les confiere la habilidad de procesar secuencias de datos. Esta propiedad las vuelve especialmente idóneas para el reconocimiento de señas dinámicas en la Lengua de Señas Mexicana (LSM), donde la información temporal es fundamental para la adecuada interpretación del significado. A diferencia de las CNN, que se centran principalmente en el análisis de las características espaciales de las imágenes, las RNN se enfocan en la evolución temporal de las señas, considerando cómo la posición y el movimiento de las manos se modifican a lo largo del tiempo.

LSTM (Long Short-Term Memory)

Las LSTM (Long Short-Term Memory) son una variante de las RNN que aborda el problema del desvanecimiento del gradiente, un obstáculo frecuente en el entrenamiento de RNN tradicionales. Este problema dificulta la captura de dependencias a largo plazo en las secuencias de datos. Las LSTM, con su arquitectura de memoria a corto y largo plazo, superan esta limitación y permiten modelar secuencias más extensas y complejas.

Arquitectura de una celda LSTM Una celda LSTM está compuesta por tres puertas principales:

- **Puerta de entrada:** Regula la entrada de nueva información a la memoria de la celda.
- **Puerta de olvido:** Determina qué información se descarta de la memoria de la celda.
- **Puerta de salida:** Controla qué información se utiliza para actualizar el estado oculto de la celda.

Ecuaciones de una celda LSTM Las siguientes ecuaciones describen el funcionamiento de una celda LSTM:

$$\begin{aligned}
i_t &= \sigma(W_{xi}x_t + W_{hi}h_{t-1} + b_i) \\
f_t &= \sigma(W_{xf}x_t + W_{hf}h_{t-1} + b_f) \\
o_t &= \sigma(W_{xo}x_t + W_{ho}h_{t-1} + b_o) \\
\tilde{c}_t &= \tanh(W_{xc}x_t + W_{hc}h_{t-1} + b_c) \\
c_t &= f_t * c_{t-1} + i_t * \tilde{c}_t \\
h_t &= o_t * \tanh(c_t)
\end{aligned}$$

donde:

- x_t : Vector de entrada en el instante t .
- h_t : Estado oculto en el instante t .
- c_t : Estado de la celda en el instante t .
- i_t, f_t, o_t : Valores de las puertas de entrada, olvido y salida, respectivamente.
- $\tilde{c}_t$: Candidato al nuevo estado de la celda.
- W_{xi}, W_{hi} , etc.: Matrices de pesos.
- b_i, b_f , etc.: Vectores de sesgo.
- σ : Función sigmoide.
- $\tanh$: Función tangente hiperbólica.

Complemento a la red neuronal convolucional En el proyecto de identificación de señas LSM, las LSTM complementan a las CNN al procesar la información temporal de las secuencias de imágenes. Mientras que las CNN extraen características espaciales de cada imagen, las LSTM modelan la evolución de estas características a lo largo del tiempo, capturando la dinámica de las señas. Esta combinación de CNN y LSTM permite un análisis más completo de las señas, mejorando la precisión del sistema de reconocimiento.

Ejemplo Para reconocer la seña "hola".^{en} LSM, que implica un movimiento de la mano, las CNN podrían identificar la forma de la mano y su posición inicial, mientras que las LSTM analizarían la trayectoria de la mano a lo largo del tiempo para confirmar que se trata del movimiento característico de la seña "hola".

En resumen, la incorporación de LSTM en el proyecto de identificación de señas LSM permite un análisis más preciso y robusto de las señas dinámicas, al considerar la información temporal en conjunto con las características espaciales extraídas por las CNN.

2.9. Funciones de Activación

Las funciones de activación introducen no linealidad en las redes neuronales, permitiendo que estas aprendan patrones complejos en los datos. Imaginemos que nuestra red se encuentra ante una bifurcación en el camino; las funciones de activación son responsables de decidir hacia dónde dirigirse.

2.9.1. Función Sigmoide

La función sigmoide transforma cualquier valor de entrada a un rango entre 0 y 1. Esta función es especialmente útil en la capa de salida para problemas de clasificación binaria, como determinar si una señal corresponde a una palabra específica.




Figura 2.3: Gráfica de la función sigmoide.

$$f(x) = \left\{ \frac{1}{1+e^{-x}} \right. \quad (2.4)$$

2.9.2. Función Tangencial Hiperbólica (tanh)

La función tangencial hiperbólica, conocida como tanh, es otra función de activación que produce valores en el rango de $(-1, 1)$. A diferencia de la sigmoide, que se limita a valores positivos, tanh puede asignar salidas tanto negativas como positivas. Esto la hace especialmente adecuada para problemas donde es necesario identificar tanto clases positivas como negativas, o en situaciones donde se requiere una salida centrada en cero.




Figura 2.4: Gráfica de la función tangencial hiperbólica (tanh).

$$f(x) = \begin{cases} -1, & \text{si } x \rightarrow -\infty \\ 1, & \text{si } x \rightarrow +\infty \\ \tanh(x), & \text{de otra manera} \end{cases} \quad (2.5)$$

La función tangencial hiperbólica (tanh), se define mediante la siguiente fórmula:

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (2.6)$$

2.9.3. Función ReLU (Rectified Linear Unit)

La función ReLU es una función lineal que retorna 0 para entradas negativas y el valor de entrada para entradas positivas. Esta función ha ganado popularidad debido a su simplicidad y eficiencia computacional. En el contexto del reconocimiento de señas, ReLU puede ser utilizada en las capas ocultas de la red neuronal para mejorar la capacidad de aprendizaje del modelo.




Figura 2.5: Gráfica de la función *ReLU*.

$$f(x) = \begin{cases} 0, & \text{si } x < 0 \\ x, & \text{si } x \geq 0 \end{cases} \quad (2.7)$$

2.9.4. Función Softmax

La función Softmax es frecuentemente utilizada en modelos de clasificación multiclase, ya que convierte las salidas de la red neuronal en probabilidades. Asigna a cada clase una probabilidad que refleja la certeza del modelo sobre su pertenencia, y la clase con la probabilidad más alta se selecciona como la predicción final. Esta función es esencial en muchas redes neuronales profundas, particularmente en la capa de salida de modelos que manejan múltiples categorías.




Figura 2.6: Gráfica de la función de activación Softmax considerando tres valores fijos $z = -1, 0, 1$.

$$\sigma(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}} \quad (2.8)$$

Las funciones de activación juegan un papel crucial en la reducción de la complejidad computacional. Esto es particularmente relevante, dado que se ejecutan para cada neurona en la red, para cada muestra y en cada ciclo de entrenamiento. Por ejemplo, con un conjunto de 1500 muestras y 10 características en una red con 4 capas de 64 neuronas cada una, esto puede traducirse en millones de ejecuciones en cada iteración de entrenamiento.

Sin funciones de activación, la red operaría de manera lineal, lo que limitaría su capacidad para aprender patrones complejos. La función sigmoide, que limita los valores entre $(0, 1)$, es útil para predecir probabilidades. Por otro lado, la tangente hiperbólica ($\tanh$) ofrece un rango de $(-1, 1)$ y es más efectiva para modelar relaciones donde las entradas negativas deben ser fuertemente negativas y las positivas fuertemente positivas.

La función ReLU, en particular, ha demostrado ser extremadamente eficaz en redes neuronales convolucionales y de aprendizaje profundo, ya que descarta las entradas negativas, lo que simplifica el proceso computacional. Por su parte, la variante Leaky ReLU evita el problema de perder información al permitir que algunos valores negativos pasen con un peso reducido.

Finalmente, la función Softmax permite realizar clasificaciones categóricas multiclase y se aplica en las capas de salida, facilitando la interpretación de las salidas de la red como probabilidades, lo que es fundamental para muchas aplicaciones de inteligencia artificial.

2.10. Entrada de Arreglos Fila (Vectores)

La entrada de datos al modelo de aprendizaje profundo se realiza en forma de arreglos fila o vectores, que representan las características extraídas de las señas capturadas por la cámara. Estos vectores contienen información sobre la seña en cada cuadro de la secuencia, permitiendo al modelo aprender a reconocer patrones y clasificar las señas [28].

2.11. Datasets para el Reconocimiento de LSM

El desarrollo de un sistema de traducción de LSM requiere un conjunto de datos robusto y diverso para entrenar y evaluar los modelos de aprendizaje profundo. Estos datasets deben contener imágenes o videos de personas realizando señas en LSM, junto con sus correspondientes traducciones al español.

2.11.1. Características de los Datasets

Los datasets ideales para el reconocimiento de LSM deben cumplir con las siguientes características:

- **Variedad de Señas:** Incluir un amplio repertorio de señas, abarcando el alfabeto, números, palabras comunes, expresiones faciales y gramática de la LSM.
- **Diversidad de Signantes:** Contener muestras de diferentes signantes con variaciones en edad, género, etnia, experiencia en LSM y estilo de señas.
- **Etiquetado Preciso:** Cada muestra debe estar etiquetada correctamente con su correspondiente traducción al español, incluyendo información sobre la seña, significado, y contexto gramatical.
- **Tamaño del Dataset:** Un mayor número de muestras generalmente mejora el rendimiento del modelo, permitiendo un aprendizaje más robusto y una mejor generalización.
- **Formato de Datos:** Los datos deben estar en un formato adecuado para el entrenamiento de modelos de aprendizaje profundo, como imágenes, videos, o secuencias de datos.

2.11.2. Entrada de Datos al Modelo

La entrada de datos al modelo de aprendizaje profundo se realiza en forma de arreglos fila o vectores, que representan las características extraídas de las señas capturadas por la cámara. Estos vectores contienen información sobre la seña en cada cuadro de la secuencia, gracias a un enfoque holístico, permitiendo al modelo aprender a reconocer patrones y clasificar las señas [28].

$$A = (a_1 \quad a_2 \quad a_3 \quad \cdots \quad a_n) \quad (2.9)$$

Donde:

- A representa el vector de características.
- $a_1, a_2, a_3, \dots, a_n$ son las características individuales extraídas de la seña, como la posición de la mano, la forma de la mano, la orientación, el movimiento, etc.

Este enfoque de representación de datos permite que el modelo capture la información espacial y temporal de la seña de manera eficiente, lo que es fundamental para un reconocimiento preciso de la LSM.

Capítulo 3

Estado del arte

Se han encontrado diversos trabajos relacionados, la mayoría con el propósito de ayudar a personas con hipoacusia que conocen alguna lengua de señas, tanto dentro del IPN como en otras universidades.

3.1. Dispositivo traductor de LSM a español escrito para la extremidad superior derecha [29]

Este proyecto se enfoca en el diseño e implementación de un prototipo de dispositivo que se coloca en la extremidad superior derecha para traducir la Lengua de Señas Mexicana (LSM) a español escrito. Este dispositivo es capaz de traducir tanto el alfabeto dactilológico como un conjunto de señas básicas de la LSM. Para lograr esto, emplea una red neuronal artificial que clasifica las señas. Además, utiliza una combinación de sensores para identificar la posición y el movimiento de la mano y el brazo, incluyendo sensores resistivos para medir la flexión y un acelerómetro y giroscopio para medir la orientación y el movimiento. Este proyecto fue desarrollado por Casa Sánchez, M. del R., en la UPIITA IPN.

3.2. Reconocimiento de las señas estáticas del LSM con características basadas en aprendizaje profundo [30]

Este proyecto se enfoca en el reconocimiento de 21 señas estáticas de la Lengua de Señas Mexicana (LSM) utilizando características extraídas por la arquitectura VGG16 y clasificadores Random Forest (RF) y Support Vector Machines (SVM). Se evalúan las características profundas extraídas en las capas fc6 y fc7 de VGG16, así como la concatenación de ambas, para identificar las señas estáticas del LSM. El proyecto destaca por el uso de MediaPipe para la extracción de características de las manos, lo que permite una captura precisa y eficiente de los datos. Además, analiza las características extraídas por VGG16 en distintas capas y su combinación para determinar las más discriminativas para el reconocimiento de señas. Finalmente, utiliza clasificadores RF y SVM para el reconocimiento de señas, demostrando su eficacia en esta tarea. Este proyecto fue desarrollado por Rafael Fernández Rodríguez, Francisco Javier Peralta Rosas, Luis Ángel Zuñiga-Madrid, y Pedro Arguijo en el Tecnológico Nacional de México, Campus Misantla.

3.3. Sistema de interpretación de imágenes para el reconocimiento y traducción del lenguaje de señas [31]

Este trabajo presenta el desarrollo de un sistema de reconocimiento de gestos que traduce imágenes a representaciones en lenguaje de señas. Utiliza OpenCV y Python para procesar imágenes, detectar y segmentar manos, y reconocer gestos predefinidos. Aunque no se enfoca específicamente en la LSM, demuestra el uso de técnicas de visión por computadora para la interpretación de señas. Emplea OpenCV para el procesamiento de imágenes y la detección de manos, lo que proporciona una base para la captura y análisis de gestos. Además, implementa técnicas de segmentación para aislar las manos del fondo de la imagen, mejorando la precisión del reconocimiento de gestos. Finalmente, utiliza algoritmos de reconocimiento de patrones para identificar gestos específicos a partir de las características extraídas de las manos. Este proyecto fue desarrollado por Dora María Calderón Nepamuceno, Gabriela Kramer Bustos, y Efrén González Gómez en la Universidad Autónoma del Estado de México, Centro Universitario Nezahualcóyotl.

3.4. Desarrollo de un intérprete de 20 frases en lengua de señas ecuatoriana a voz en tiempo real usando redes neuronales recurrentes [32]

Este proyecto se centra en el desarrollo de un intérprete en tiempo real que traduce 20 frases de la Lengua de Señas Ecuatoriana (LSEC) a voz. Su objetivo principal es facilitar la comunicación entre personas sordas y oyentes, mejorando la accesibilidad e inclusión de la comunidad sorda. El sistema se caracteriza por procesar y traducir las señas a voz de manera instantánea, enfocarse específicamente en la Lengua de Señas Ecuatoriana, y emplear Redes Neuronales Recurrentes (RNNs), en particular una combinación de CNN y LSTM, para analizar y comprender las secuencias de gestos que componen las frases en LSEC. Desarrollado por Guevara Sanandrés, Juan Diego en la EPN.

3.5. Las redes neuronales convolucionales en el uso de lenguaje de señas en la gestión académica de los estudiantes para SENATI [33]

Esta tesis explora la aplicación de redes neuronales convolucionales (CNN) para el reconocimiento del lenguaje de señas en el contexto de la gestión académica de estudiantes en el Servicio Nacional de Adiestramiento en Trabajo Industrial (SENATI). Se destacan dos aspectos principales: el empleo de CNN, un tipo de red neuronal profunda especializada en el procesamiento de imágenes, para analizar y reconocer los gestos del lenguaje de señas; y el enfoque en la aplicación práctica de la tecnología en procesos académicos como la atención al estudiante y consultas sobre especialidades. Desarrollado por Hugo Alejandro Mamanchura Lima en la UPLA.

3.6. Diseño e implementación de un sistema de traducción de lenguaje de señas dactilológico a lenguaje natural escrito para personas no hablantes mediante visión artificial [34]

Este proyecto se centra en el diseño e implementación de un sistema que utiliza visión artificial para traducir el lenguaje de señas dactilológico (deletreo con los dedos) al español escrito, con el objetivo de mejorar la comunicación de las personas no hablantes. El sistema emplea técnicas de visión artificial

para capturar y procesar los gestos de las manos en tiempo real. Utiliza la biblioteca MediaPipe para la detección y seguimiento de manos, lo que permite identificar 21 puntos de referencia en la mano para un análisis preciso. Además, implementa una Red Neuronal Convolutiva (CNN) para clasificar los gestos de las manos y traducirlos a letras del alfabeto. Desarrollado por Cusme Quintanilla, Medellín en la Escuela Superior Politécnica de Chimborazo.

3.7. Reconocimiento de señas de la Lengua de Señas Mexicana mediante técnicas de Machine Learning [35]

Este artículo evalúa el rendimiento de diferentes técnicas de Machine Learning (Aprendizaje Automático) para reconocer señas del alfabeto dactilológico de la Lengua de Señas Mexicana (LSM). Se recolectó un conjunto de datos de imágenes de señas y se entrenaron modelos utilizando cuatro técnicas. El estudio se enfoca en el reconocimiento de señas del alfabeto dactilológico de la LSM, que no involucran movimiento. Se comparan cuatro técnicas para el reconocimiento de señas: CNN, Transfer Learning, Teachable Machine y CNN con características específicas. Para el entrenamiento y la evaluación, se utilizó un conjunto de datos propio de imágenes de señas. En una de las técnicas, se extrajeron características específicas de las imágenes (coordenadas de puntos de referencia en las manos) para mejorar el rendimiento del modelo. Desarrollado por Gabriel A. Salgado-Martínez, René E. Cuevas-Valencia, Angelino Feliciano-Morales, y Arnulfo Catalán-Villegas en la Escuela Superior de Tlahuelil.

3.8. Desarrollo de un Sistema Web intérprete de la Lengua de Señas Argentina [29]

Esta tesis presenta el desarrollo de un sistema web que interpreta un conjunto de señas de la Lengua de Señas Argentina (LSA) en tiempo real o a partir de videos pregrabados. El sistema utiliza modelos de aprendizaje automático, incluyendo árboles de decisión optimizados (XGBoost) y redes neuronales recurrentes (RNN, específicamente LSTM y GRU), para traducir secuencias de imágenes (videos) a su correspondiente texto en español. El sistema es capaz de procesar videos tanto en tiempo real como pregrabados, extrayendo información relevante de las secuencias de imágenes. Para la detección y seguimiento de manos, utiliza la biblioteca MediaPipe, lo que facilita la extracción de características de los gestos. Desarrollado por Facundo Nicolas Recabarren Martin en la Universidad Nacional de San Juan, Facultad de Ciencias Exactas, Físicas y Naturales, Departamento de Informática.

3.9. Desarrollo de algoritmos para Traductor automático de lenguaje de señas Mexicanas (LSM) [36]

Esta tesis doctoral se enfoca en el desarrollo de algoritmos para la traducción automática del Lenguaje de Señas Mexicano (LSM). Aborda el desafío de reconocer y clasificar señas a partir de secuencias de imágenes, considerando aspectos como el movimiento de las manos, la posición corporal y los puntos de contacto. El análisis de videos de señas se realiza extrayendo 15 cuadros por palabra y enfocándose en regiones de interés, como las manos y la cara. Se utilizan características geométricas, como área, redondez, longitud del borde, elongación, centro de gravedad y densidad, para describir las señas. Para la clasificación, se emplean y comparan diferentes algoritmos, incluyendo Support Vector Machines (SVM), árboles de decisión, clasificador bayesiano y redes neuronales, para evaluar su eficacia en el reconocimiento de señas. Desarrollado por Josué Espejel Cabrera en la Universidad Autónoma del Estado de México.

3.10. Sistema multi-agente de reconocimiento de frases en LSM utilizando CBR [37]

Esta tesis presenta el desarrollo de un sistema multi-agente que reconoce frases en Lengua de Señas Mexicana (LSM) y las traduce a través de un avatar en un dispositivo móvil. El sistema utiliza la técnica de Razonamiento Basado en Casos (CBR) para mejorar su capacidad de comunicación al aprender de nuevas frases. Se enfoca en el reconocimiento de frases completas en LSM, en lugar de palabras aisladas, lo que permite una comunicación más natural y fluida. Emplea una arquitectura multi-agente, donde cada agente tiene una tarea específica, como recibir la frase, procesarla y proyectar la traducción. El uso de CBR permite almacenar y reutilizar experiencias pasadas, lo que permite al sistema aprender de nuevas frases y mejorar su precisión con el tiempo. Desarrollado por Ing. César René Martínez Aguirre en el Instituto Tecnológico de Hermosillo.

3.11. Modelos Computacionales Aplicados a la Lengua de Señas Mexicana [38]

Esta tesis se enfoca en el desarrollo y evaluación de un sistema para reconocer la dactilología (alfabeto manual) y los primeros diez números de la Lengua de Señas Mexicana (LSM) utilizando visión computacional y técnicas de aprendizaje automático y profundo. Se creó una base de datos propia de LSM y se aplicó MediaPipe para la extracción de características de las manos, obteniendo 21 puntos de referencia por mano. Se entrenaron y compararon modelos como Support Vector Machine (SVM) para reconocer las señas estáticas y Gated Recurrent Unit (GRU) para el reconocimiento de señas continuas. Desarrollado por Ing. Mario Emmanuel Rodríguez Trejo en la Universidad Autónoma del Estado de Morelos.

3.12. Modelo para la creación y uso de un repositorio digital de segmentos visuales en lengua de señas mexicanas utilizando Inteligencias Artificial [39]

Esta tesis propone un modelo para crear y utilizar un repositorio digital de segmentos visuales en Lengua de Señas Mexicana (LSM) usando inteligencia artificial. El objetivo es mejorar la plataforma de traducción español-LSM desarrollada previamente en el Instituto Tecnológico de Hermosillo, facilitando la comunicación entre personas sordas y oyentes en contextos educativos. El repositorio almacena segmentos visuales de señas en LSM extraídos de videos disponibles en la web. Utiliza técnicas de visión e inteligencia artificial para extraer automáticamente las señas y su texto correspondiente de los videos. Además, convierte los segmentos de video en representaciones 3D animadas utilizando el modelo SMPL, permitiendo una visualización más realista y versátil. Desarrollado por Maria Luisa Galaz Palma en el Instituto Tecnológico de Hermosillo.

Capítulo 4

Análisis

En este capítulo se describen los requerimientos para el funcionamiento del sistema, así como los componentes de hardware y software que se deberán seleccionar para su correcto desarrollo e implementación.

4.1. Análisis de Requerimientos del Sistema

4.1.1. Funcionalidad del sistema

A continuación, se presenta un análisis exhaustivo de las capacidades principales del sistema, visualizadas mediante un diagrama de casos de uso.

La Figura 4.1 presenta el diagrama de casos de uso denominado "Sistema General", en el que el actor principal es el SEÑANTE. Este actor puede realizar dos acciones fundamentales dentro del sistema: acceder al sistema e interactuar con el módulo de LSM. Estas acciones reflejan las interacciones básicas necesarias para que el SEÑANTE pueda utilizar las funcionalidades del sistema asociadas a la Lengua de Señas Mexicana (LSM).

Asimismo, el diagrama incluye al usuario administrador (ADMIN), quien desempeña un rol específico en el sistema y tiene asignadas diversas tareas relacionadas con la gestión de la plataforma.




Figura 4.1: Diagrama de casos de uso del Sistema Principal

4.2. Requerimientos Funcionales (RF)

Los requerimientos del sistema, derivados del análisis realizado a través del Diagrama de Casos de Uso, se detallan en las Tablas 4.1 a 4.8. Estos requerimientos se centran en las funcionalidades que permiten la interacción del usuario con el sistema para el reconocimiento y la interpretación de la Lengua de Señas Mexicana (LSM). A continuación, se presentan estos requerimientos de manera organizada:

Identificación del requerimiento	RF01
Nombre del requerimiento	Registro de Usuario
Definición del requerimiento	El sistema debe permitir registrar a un usuario que emitirá muestras.
Descripción del requerimiento	El sistema debe permitir que el usuario señante se registre ingresando su correo y contraseña.
Precondiciones requeridas	El sistema debe tener habilitadas las opciones de registro de usuario.
Prioridad del requerimiento	Alta

Cuadro 4.1: *Requerimiento: Registro de Usuario*

Identificación del requerimiento	RF02
Nombre del requerimiento	Inicio de la App
Definición del requerimiento	El sistema debe iniciar la aplicación para tomar las muestras.
Descripción del requerimiento	El usuario debe poder abrir la app para comenzar la captura de señas.
Precondiciones requeridas	El sistema debe estar instalado y operativo.
Prioridad del requerimiento	Alta

Cuadro 4.2: *Requerimiento: Inicio de la App*

Identificación del requerimiento	RF03
Nombre del requerimiento	Login
Definición del requerimiento	El sistema debe permitir que los usuarios inicien sesión.
Descripción del requerimiento	El sistema debe autenticar al usuario mediante un inicio de sesión seguro con correo y contraseña.
Precondiciones requeridas	El usuario debe haber sido registrado previamente en el sistema.
Prioridad del requerimiento	Alta

Cuadro 4.3: *Requerimiento: Login*

Identificación del requerimiento	RF04
Nombre del requerimiento	Autenticación de Credenciales
Definición del requerimiento	El sistema debe autenticar las credenciales de los usuarios.
Descripción del requerimiento	El sistema debe verificar que el usuario persista en el sistema y que la contraseña coincida con la registrada.
Precondiciones requeridas	El usuario debe existir en el <i>bucket S3</i> del sistema.
Prioridad del requerimiento	Alta

Cuadro 4.4: *Requerimiento: Autenticación de Credenciales*

Identificación del requerimiento	RF05
Nombre del requerimiento	Perfil
Definición del requerimiento	El sistema debe permitir al usuario gestionar su perfil.
Descripción del requerimiento	El usuario puede ver y actualizar sus datos personales, como nombre, correo y foto de perfil.
Precondiciones requeridas	El usuario debe haber iniciado sesión correctamente.
Prioridad del requerimiento	Alta

Cuadro 4.5: *Requerimiento: Perfil*

Identificación del requerimiento	RF06
Nombre del requerimiento	Destacados
Definición del requerimiento	Ver nombre de los usuarios destacados (destacan por la cantidad de señas que emiten).
Descripción del requerimiento	El sistema debe permitir al SEÑANTE ver la lista de usuarios que más han emitido muestras de señas para el sistema.
Precondiciones requeridas	El usuario señante debe estar autenticado.
Prioridad del requerimiento	Media

Cuadro 4.6: *Requerimiento: Destacados*

Identificación del requerimiento	RF07
Nombre del requerimiento	DLM (Ver Información de la Seña)
Definición del requerimiento	El sistema debe permitir al usuario ver información detallada de la seña seleccionada.
Descripción del requerimiento	El usuario debe acceder a información completa de una seña específica que persista en el sistema y en el <i>bucket S3</i> .
Precondiciones requeridas	El usuario debe estar autenticado.
Prioridad del requerimiento	Alta

Cuadro 4.7: *Requerimiento: DLM (Ver Información de la Seña)*

Identificación del requerimiento	RF08
Nombre del requerimiento	Inicio del Sistema
Definición del requerimiento	El sistema debe permitir iniciar la plataforma correctamente para que los usuarios puedan emitir la señal.
Descripción del requerimiento	El sistema debe cargar los componentes necesarios al inicio para permitir la interacción del usuario con la aplicación.
Precondiciones requeridas	El sistema debe estar instalado correctamente en el dispositivo del usuario.
Prioridad del requerimiento	Alta

Cuadro 4.8: *Requerimiento: Inicio del Sistema*

Identificación del requerimiento	RF09
Nombre del requerimiento	Captura de Señal a Identificar
Definición del requerimiento	El sistema debe permitir la captura de una señal para su posterior identificación.
Descripción del requerimiento	El usuario deberá capturar una señal y el sistema la procesará para intentar identificarla.
Precondiciones requeridas	El sistema debe tener la capacidad de procesar imágenes o secuencias de video.
Prioridad del requerimiento	Alta

Cuadro 4.9: *Requerimiento: Captura de Señal a Identificar*

Identificación del requerimiento	RF10
Nombre del requerimiento	Reconocer
Definición del requerimiento	El sistema debe reconocer la señal capturada.
Descripción del requerimiento	El sistema debe procesar la señal capturada y devolver el nombre o significado asociado.
Precondiciones requeridas	La señal debe estar correctamente capturada y registrada en el sistema, en el <i>bucket S3</i> , y debe estar entrenado el algoritmo.
Prioridad del requerimiento	Alta

Cuadro 4.10: *Requerimiento: Reconocer*

Identificación del requerimiento	RF11
Nombre del requerimiento	Registra Información de Señal DLM
Definición del requerimiento	El sistema debe permitir registrar información detallada de cada señal en el sistema y en el <i>bucket S3</i> .
Descripción del requerimiento	El usuario administrador debe poder registrar nueva información de señales en el sistema, incluyendo su nombre, descripción y animación.
Precondiciones requeridas	El usuario debe tener permisos de administrador.
Prioridad del requerimiento	Alta

Cuadro 4.11: *Requerimiento: Registra Información de Señal DLM*

Identificación del requerimiento	RF12
Nombre del requerimiento	Captura de Señal en Bucket
Definición del requerimiento	El sistema debe permitir la captura de señales para almacenarlas en el <i>bucket S3</i> .
Descripción del requerimiento	El sistema debe capturar señales a través de la cámara y almacenarlas en el <i>bucket S3</i> para su posterior identificación.
Precondiciones requeridas	El sistema debe tener configurado un <i>bucket S3</i> con la capacidad de almacenar las imágenes y datos relacionados con las señales.
Prioridad del requerimiento	Alta

Cuadro 4.12: *Requerimiento: Captura de Señal en Bucket*

Bibliografía

- [1] Instituto Nacional de Estadística y Geografía (INEGI). *La discapacidad en México, datos al 2014*. Disponible en: <https://www.inegi.org.mx/>. [Accedido: 2024-11-04]. 2016.
- [2] T. C. Smith-Stark. *La lengua manual mexicana*. Trabajo no publicado, Colegio de México. [Accedido: 2024-11-04]. 1986.
- [3] Y. He et al. *MediaPipe Hands: On-device real-time hand tracking*. Disponible en: <https://doi.org/10.48550/arXiv.2006.10214>. [Accedido: 2024-11-04]. 2020.
- [4] M. Abadi et al. *TensorFlow: A system for large-scale machine learning*. Disponible en: <https://www.usenix.org/system/files/conference/osdi16/osdi16-abadi.pdf>. [Accedido: 2024-11-04]. 2016.
- [5] Amazon Web Services. *Scalable cloud infrastructure with AWS S3 and SQS*. Disponible en: <https://docs.aws.amazon.com/>. [Accedido: 2024-11-04]. 2022.
- [6] F. P. Priego Pérez. *Reconocimiento de imágenes del Lenguaje de Señas mexicano*. Centro de Investigación en Computación. [Accedido: 2024-11-04]. 2012.
- [7] P. Hindley y N. Kitson. *Mental health and deafness*. The British Journal of Psychiatry, 176(1), 52-57. [Accedido: 2024-11-04]. 2000.
- [8] O. Pichardo-Lagunas, L. Partida-Terrón, B. Martínez-Seis et al. *Sistema de traducción directa de español a LSM con reglas marcadas*. Revista de Investigación en Computación. [Accedido: 2024-11-04]. 2016.
- [9] M. E. S. de Fleischmann y R. González Pérez. *Diccionario de Lengua de Señas Mexicana*. Consejo Nacional para Prevenir la Discriminación. [Accedido: 2024-11-04]. 2011.
- [10] G. García-Bautista, F. Trujillo-Romero y S. O. Caballero-Morales. *Mexican sign language recognition using Kinect and data time warping algorithm*. Disponible en: <https://doi.org/10.1109/CONIELECOMP.2017.7891832>. [Accedido: 2024-11-04]. 2017.
- [11] R. Pugliese y A. Guerriero. *Sign language recognition: The leap motion controller approach*. Disponible en: <https://www.springer.com/>. [Accedido: 2024-11-04]. 2017.
- [12] M. García-Ortiz et al. *Mexican sign language recognition using convolutional neural networks and transfer learning*. Disponible en: <https://doi.org/10.1109/CCE.2019.00006>. [Accedido: 2024-11-04]. 2019.
- [13] M. H. O'Malley. *Text-to-speech conversion technology*. Disponible en: <https://doi.org/10.1109/2.56867>. [Accedido: 2024-11-04]. 1990.
- [14] K. Faurot et al. *The identity of Mexican sign as a language*. Disponible en: <http://www.sil.org/silesr/2000/2000-002/>. [Accedido: 2024-11-04]. 1992.
- [15] M. E. S. de Fleischmann. *Estrategia pedagógica para la enseñanza del español signado de México*. Disponible en: <http://www.libreacceso.org/wp-content/uploads/2014/04/EstrategiaPedagogica.pdf>. [Accedido: 2024-11-04]. 2014.
- [16] T. Skutnabb-Kangas y R. Phillipson. *Linguistic human rights, past and present*. En Linguistic human rights: Overcoming linguistic discrimination. [Accedido: 2024-11-04]. 1994.

- [17] A. Estévez. *Desarrollo e implementación de un sistema de identificación de signos de la lengua de señas mexicana basado en redes neuronales y el sistema embebido Jetson Nano*. Tesis de licenciatura, Universidad Tecnológica de la Mixteca. [Accedido: 2024-11-04]. 2022.
- [18] D. Crystal. *A dictionary of linguistics and phonetics (5th ed.)* Blackwell Publishing. [Accedido: 2024-11-04]. 2003.
- [19] C. E. Escobedo Delgado. *Diccionario de Lengua de Señas Mexicana LSM*. Disponible en: https://pdh.cdmx.gob.mx/storage/app/media/banner/Dic_LSM\%202.pdf. [Accedido: 2024-11-04]. 2017.
- [20] H. Kniberg. *Scrum y XP desde las trincheras: Cómo hacemos Scrum*. C4Media Inc., 2007.
- [21] Asana. *Scrum: conceptos clave y cómo se aplica en la gestión de proyectos*. Disponible en: <https://asana.com/es/resources/what-is-scrum>. [Accedido: 2024-11-04]. 2024.
- [22] L. Pigou et al. *Sign language recognition using convolutional neural networks*. Disponible en: <https://www.springer.com/>. [Accedido: 2024-11-04]. 2014.
- [23] Google. *MediaPipe Holistic*. Disponible en: https://ai.google.dev/edge/mediapipe/solutions/vision/holistic_landmarker?hl=es-419. [Accedido: 2024-11-04]. 2023.
- [24] M. Abadi et al. *TensorFlow: Large-scale machine learning on heterogeneous systems*. Disponible en: <https://www.tensorflow.org>. [Accedido: 2024-11-04]. 2015.
- [25] R. Dautov y S. Distefano. “Hybrid machine learning: Combining the power of cloud and edge computing”. En: *2018 IEEE 16th World Symposium on Applied Machine Intelligence and Informatics (SAMII)*. IEEE. 2018, págs. 000181-000186.
- [26] M. del S. Cruz Aldrete. *Análisis lingüístico de la Lengua de Señas Mexicana*. Plaza y Valdés, 2004.
- [27] S. Newman. *Building microservices*. O’Reilly Media, Inc., 2015.
- [28] S. Bayraci, B. Akgun y M. F. Amasyali. “Deep neural network (DNN) based classification model in application to loan default prediction”. En: *2018 6th International Conference on Control Engineering Information Technology (CEIT)*. IEEE. 2019, págs. 1-5.
- [29] M. del R. Casa Sánchez. *Dispositivo traductor de LSM a español escrito para la extremidad superior derecha*. Tesis de Ingeniería en Mecatrónica, Instituto Politécnico Nacional, UPIITA. [Accedido: 2024-11-04]. 2022.
- [30] R. Fernández Rodríguez, F. J. Peralta Rosas y L. Á. Zuñiga-Madrid. “Reconocimiento de las señas estáticas del LSM con características basadas en aprendizaje profundo”. En: *Revista Científica de Ingeniería y Tecnología* 150.6 (2021). [Accedido: 2024-11-04], págs. 1-12.
- [31] D. M. Calderón Nepamuceno, G. Kramer Bustos y E. González Gómez. “Sistema de interpretación de imágenes para el reconocimiento y traducción del lenguaje de señas”. En: *Revista Científica de Ingeniería y Tecnología* 152.8 (2023). [Accedido: 2024-11-04].
- [32] J. D. Guevara Sanandrés. “Desarrollo de un intérprete de 20 frases en lengua de señas ecuatoriana a voz en tiempo real usando redes neuronales recurrentes”. Tesis de mtría. Escuela Politécnica Nacional, Quito, 2022.
- [33] H. A. Mamanchura Lima. “Las redes neuronales convolucionales en el uso de lenguaje de señas en la gestión académica de los estudiantes para SENATT”. Tesis de mtría. Universidad Peruana Los Andes, 2022.
- [34] M. L. Cusme Quintanilla. *Diseño e implementación de un sistema de traducción de lenguaje de señas dactilológico a lenguaje natural escrito para personas no hablantes mediante visión artificial*. Trabajo de titulación de Ingeniería en Telecomunicaciones, Escuela Superior Politécnica de Chimborazo. [Accedido: 2024-11-04]. 2024.
- [35] G. A. Salgado-Martínez et al. “Reconocimiento de señas de la Lengua de Señas Mexicana mediante técnicas de Machine Learning”. En: *XIKUA Boletín Científico de la Escuela Superior de Tlahuelilpan* 12.Especial (2024). [Accedido: 2024-11-04], págs. 33-39.

- [36] J. Espejel Cabrera. “Desarrollo de algoritmos para Traductor automático de lenguaje de señas Mexicanas (LSM)”. Tesis doct. Universidad Autónoma del Estado de México, 2021.
- [37] C. R. Martínez Aguirre. “Sistema multi-agente de reconocimiento de frases en LSM utilizando CBR”. Tesis de mtría. Instituto Tecnológico de Hermosillo, 2020.
- [38] M. E. Rodríguez Trejo. “Modelos Computacionales Aplicados a la Lengua de Señas Mexicana”. Tesis de mtría. Universidad Autónoma del Estado de Morelos, 2023.
- [39] M. L. Galaz Palma. “Modelo para la creación y uso de un repositorio digital de segmentos visuales en lengua de señas mexicanas utilizando Inteligencias Artificial”. Tesis de mtría. Instituto Tecnológico de Hermosillo, 2022.